

# Arthur

Projektna dokumentacija

RECURRENT

Filip Šaina

# Sadržaj

1.	Pregled izazova .....	3
2.	Implementacija i opis rješenja.....	4
2.1.	Problem vremenske predikcije.....	4
2.2.	Konstrukcija podatkovnog skupa.....	5
2.2.1.	Izlazni podatci.....	5
2.2.1.	Ulazni podatci.....	6
2.3.	LSTM mreže.....	7
2.3.1.	Definiranje modela, treniranje i evaluacija.....	8
2.3.2.	Zaključak.....	10
2.4.	Web aplikacija.....	11
2.4.1.	Korištene tehnologije.....	12
3.	Industrijski benefiti sustava.....	13
4.	Sugestije za daljnje poboljšanje sustava.....	14
6.	Reference.....	15

# 1. Pregled izazova

Zvijezda, kao ekološki svjesna kompanije, želi pozitivno utjecati na okoliš i uštedjeti na potrošnji električne energije. Potrebno je osmisliti:

- sustav koji će povezati utjecaj vanjske temperature na potrošnju električne energije postrojenja
- matematički model na temelju danih, ulaznih podataka te napraviti prediktivnu analizu na temelju povijesnih podataka i meteoroloških predviđanja za buduće razdoblje<sup>1</sup>.

U problemu se analizira skladište Zagrebačkog proizvodnog pogona Zvijezde d.d., te kroz razgovore sa voditeljem odjela elektro održavanja, Dariom Požgajecom, zaključak je da bi iz njegove perspektive, kao korisnika sustava, optimalan bio sustav za predikciju snage( a samim time i energije ). Koliko je bitno imati sustav za predikciju ponašanja potrošnje ovisno o vremenskih čimbenicima najbolje govore sljedeće informacije :

- Potrošnja električne energije analiziranog skladišta čini 17.34% ukupne potrošnje električne energije od 9.270.000,00 kWh<sup>2</sup> i treći je najveći potrošač u Zvijezdi d.d.
- Snagu koju skladište povuče u ljetnim mjesecima kreće se otprilike oko 450kW (max. snaga u 15 min. periodi zabilježena u dotičnom mjesecu)

Idealni sustav predikcije bi dakle trebao biti:

- točan u predikciji pomoću vremenskih podataka
- jednostavan za uporabu
- fleksibilan po pitanja duljine vremenske predikcije

---

<sup>1</sup> Preuzeto sa originalnog teksta zadatka — [inovativko.mstart.hr](http://inovativko.mstart.hr)

<sup>2</sup> za referentni period (od 04/2014 do 04/2015 godine)

## 2. Implementacija i opis rješenja

### 2.1. Problem vremenske predikcije

Problemi vremenske predikcije pripadaju fokusu studija velikog broja znanstvenih disciplina, poput teorije informacija, obradi digitalnih signala, strojnom učenju itd. Mnogobrojni radovi na ovu temu<sup>3</sup> pokazuju da je ovo još uvijek aktivna grana znanosti, te sa nedavnim napretkom u dubokom učenju i strojnom učenju, imamo sve više korisnih alata za rješavanje ovih problema.

Problem predikcije vremenskih serija pripada grupi problema za koje je potrebno modelirati memoriju ili svojstvo pamćenja stanja, te kod koji buduće vrijednosti ovise o prošlim stanjima<sup>4</sup>. Primjerice, za niz brojeva u vremenu trebamo predvidjeti idući u nizu:

1,2,3,4,3,2,1,2,3,4,3, ?

Samo na temelju informacije da je trenutna vrijednost iznosi 3 nije dovoljna da zaključimo hoće li idući broj biti 4 ili 2 — oba odabira su jednako validna. Zbog toga moramo gledati više koraka u prošlost, te na temelju informacije da su prethodna dva broja bila 4 i 3 zaključiti da će idući broj sigurno biti 2.

U problemima obrade podataka poznato je svojstvo modela pod nazivom eng. *complexity-interpretability tradeoff*, koje nalaže da modeli mogu biti kompleksni ili interpretabilni ali ne oboje istovremeno. Kompleksni modeli nude generalno bolje performanse ali ograničenu interpretabilnost interne logike prema kojima oni dolaze do rezultata, dok interpretabilni obratno. Primjer interpretabilnog modela je linearna regresija, pomoću koje možemo primjerice točno izračunati koeficijent kolinearnost među varijablama<sup>5</sup>. Kako interpretacija podataka nije primarni cilj zadatka, već kvalitetna predikcija, rad se u nastavku fokusira na kompleksne modele strojnog i dubokog učenja.

---

<sup>3</sup> Na kraju rada dodane su reference nekih od radova na temu vremenskih predikcija i radova na temu predikcija pomoću LSTM mreža.

<sup>4</sup> U suprotnom — ako buduća raspodjela vjerojatnosti procesa, za dano trenutno stanje i sva prošla stanja, ovisi samo o trenutnome stanju i niti o jednom drugome prethodnom, tada takav proces nazivamo markovljevim.

<sup>5</sup> Zanimljiv primjer je podakovni skup analiziran u knjizi *Introduction to statistical learning* u kojoj se dolazi do zaključka na korištenom datasetu da postoji savršena kolinearnost između broja prodanih sladoleda na plaži i napada morskih pasa. Zaključak je da je ovo zapravo varljiv podataka pošto obe variable ovise o jednoj skrivenoj varijabli — temperaturi, pa ispravna interpretacija glasi: ako je visoka temperatura na plaži, biti će prodano više sladoleda ali i biti će više napada morskih pasa jer će se više ljudi kupati.

## 2.2. Konstrukcija podatkovnog skupa


### 2.2.1. Izlazni podatci

Podatkovni skup dobiven od Zvijezda d.d. skladišta za potrebe natjecanja dijeli se na 3 glavne mjerne točke :

- potrošnja za rashladni uređaj br. 1
- potrošnja za rashladni uređaj br. 2
- podatci za glavni razvodni ormar

Svaka od tih mjernih točaka arhivira prosječne 15 minutne snage i to odvojeno za prvu tarifu te za drugu tarifu. Snaga *P15\_1* ima iznos mjerenja u periodu I tarife dok je u periodu II tarife jednak nuli. Ista logika je i za *P15\_2*. Stupac *xxx\_time* predstavljaju vremensku os za pojedinu veličinu<sup>6</sup>, odnosno trenutak mjerenja.

Podatci se zatim preprocesiraju, te uzimaju prosječne vrijednosti svih mjerenja za jedan dan za prvi i drugu tarifu. Odnosno, ne radi se distinkcija po tarifi jer samo mjerenje je nezavisno o tarifi kojoj pripada. Krajnji rezultat je podatkovni skup koji se sastoji of niza prosječnih dnevnih prosječnih potrošnji za period od 792 dana — kako je ilustrirano u slici 1.



Slika 1. Diagram dnevne prosječne potrošnje u kWh za 2 godine

<sup>6</sup> *P15\_1*, *P15\_2*, *xxx\_time* predstavljaju stupce u dobivenim podacima

### 2.2.2. Ulazni podatci

Potrebno je bilo konstruirati podatkovni skup ulaznih podataka. Ulazni podatci su preuzeti sa [darksky.net](http://darksky.net) (prethodno poznat kao [forecast.io](http://forecast.io))<sup>7</sup> i sastoje se od sljedećih parametara za svaki dan :

- maksimalna temperatura
- minimalna temperatura
- osjetna maksimalna temperatura
- osjetna minimalna temperatura
- vlažnost
- brzina vjetra
- smjer vjetra
- postotak naoblacenja
- pritisak zraka
- temperatura kondenzacije
- lunarna faza mjeseca

Od vrijednosti koje su ručno konstruirane, dodana je i labela za dan u tjednu, pritom je svaki dan numeriran labelom od 1 do 7. Tokom faze treniranja modela ova vrijednost se pokazala iznimno korisnom jer je značajno snizila greške u predikciji. Ovime sveukupno imamo 12 ulazni varijabli po danu koje pokušavamo povezati sa jednom izlaznu vrijednošću — prosječnom potrošnjom za taj dan. Konačni podatkovni skup se sastoji od 792 primjera, odnosno dana.

Velik broj intuitivno nepotrebnih informacija odabranih za ulaz nije problem jer model, koji opisujemo u daljnjem tekstu, mora sam prepoznati koje variable su mu značajne a koje nisu, te iz tog razloga uključujemo sve<sup>8</sup>.

Sve prethodno navedene vrijednosti su pritom normalizirane i standardizirane pomoću paketa Scikit-learn<sup>9</sup>.

---

<sup>7</sup> Podatci su preuzeti sa navedene stranice zbog besplatnog pristupa vremenskim podacima unazad 5 godina. Primarno je bilo zamišljeno preuzeti podatke sa DHMZ-a, no ti podatci se naplaćuju.


<sup>8</sup> Methoda poznata kao engl. kitchen sink

<sup>9</sup> <http://scikit-learn.org>

## 2.3. LSTM mreže

Kroz protekle godine popularnost (slika 2.) Long-Short Term Memory(LSTM) neuronskih mreža je opravdana zbog iznimno dobrih performansi koje one postižu na raznim problemskim zadacima. Primjer uporabe ovakvih modela je u problemima vremenskih serija, računalnom vidu, NLP-u<sup>10</sup> za probleme klasifikacija ili generiranja opisnog teksta iz slika u kojoj LSTM mreža nauči opisivati ljudskim jezikom što “vidi” na fotografiji (referenca 5.). Iz tog razloga, za primarni model koji će biti korišten kroz rad su upravo LSTM mreže. LSTM mreže predstavljaju svojevrsnu evoluciju iz Recurrent neural network (RNN) modela jer rješavaju engl. vanishing gradient problem zbog kojeg su RNN modeli ograničeni na manji set problema kojih mogu riješiti.

Principi rada LSTM mreža nisu unutar obima ovog rada već deskriptivnost i reproduktabilnost samih rezultata i sustava, pa iz tog razloga neće biti opisivani.




Slika 2. Pregled Google Trends stranice za pojam LSTM od 2004. do danas

<sup>10</sup> engl. Natural language processing

### 2.3.1. Definiranje modela, treniranje i evaluacija

Model koji se koristi u sustavu sastoji se od dvije LSTM povezane mreže kako je vidljivo na Slici 3. Dimenzije ulaza-izlaza su sljedeće: 12x30, 30x50, 50x1. Na svaki od izlaza LSTM mreže dodan je dropout faktor od 15 % zbog bolje robusnosti modela na *overfitting*. Na izlaznom sloju implementirana je linearna aktivacijska funkcija. Glavna metrika za određivanje greške je *mean squared error (MSE)*, a za metodu optimizaciju se koristi *RMSprop*. Podatkovni skup za treniranje je podijeljen na setove za treniranje, validaciju i testiranje, 70% 20% 10% respektabilno. Od ostalih bitnih hiperparametra bitno je napomenuti da je veličina prozora vremenske serije (broj dana koje gledamo unatrag) jednak 2 zbog najboljih evaluacijskih rezultata — Slika 4. Te je za faktor učenja za RMSprop optimizator odabrano 0.000154 — Slika 5.

Za implementaciju navedenog modela korištena je popularna biblioteka za duboko i strojno učenje — Keras, Tensorflow. Svi ostali hiperparametri nisu modificirani te njihove standardne vrijednosti su dostupne u službenoj dokumentaciji alata<sup>11</sup>.




Slika 3. Grafički prikaz modela


U fazi treniranja, za završni model, vrijednost Mean Squared Error(MSE) vrijednosti iznosi **0.01610** za validacijski set te **0.01703** za test set. Vizualizacija predikcije vidljiva je na Slici 6.

<sup>11</sup> <https://keras.io/>





Slika 4. Vizulizacija treniranja modela po duljini prozora pogleda u povijest. Vrijednost dana (s desna na lijevo) od 1 do 8. Dobiveno pomoću TensorFlow alata.




Slika 5. Vizulizacija treniranja modela duljini prozora pogleda u povijest 2 sa learning rate vrijednostima 0.000154, 0.000155, 0.000156

### 2.3.2. Zaključak

Trenirani sustav, kao što je prethodno pokazano, pokazuje iznimno dobre rezultate u predikciji te uspijeva uloviti trendove potrošnje koji se javljaju u podatkovnom skupu. Iznos MSE greške, provedeno na test setu, od samo **0.01703** pokazatelj je da sustav funkcionira iznimno dobro. Bitno je za primjetiti da za vrijeme treniranja sve vrijednosti temperature su apsolutno točne pošto znamo da su se sa sigurnošću desile.

U trenutku predikcije ovo neće biti slučaj jer ćemo raditi na temelju podataka koji već u sebi imaju grešku (vremenska prognoza), te još bitnije, svaki dan dalje u budućnost za koji predviđamo imati će sve veću grešku zbog prirode problema predikcije vremenske prognoze.

Iz tog razloga nužno je minimizirati grešku koju sustav može unijeti kroz predikcije. Jedna bitna arhitekturna odluka donesena je kroz razgovore sa predstavnicima Državnog hidrometeorološkog zavoda( DHMZ ) i voditeljem odjela elektro održavanja, Dariom Požgajecom. Umjesto satne predikcije radi se dnevna predikcija. Točno odrediti kolika će biti temperatura, vlaga itd. za 5 dana u 13:00 sati je puno teže od određivanja istih parametara za cijeli dan. Kako bi se izbjegla akumulacija greške ulaznih podataka u satnim predikcijama, odabrano je dnevno predviđanje. Također, satna predikcija se nije pokazala od nikakve važnosti za korisnika sustava(primarno voditelja skladišta) — već samo dnevna.



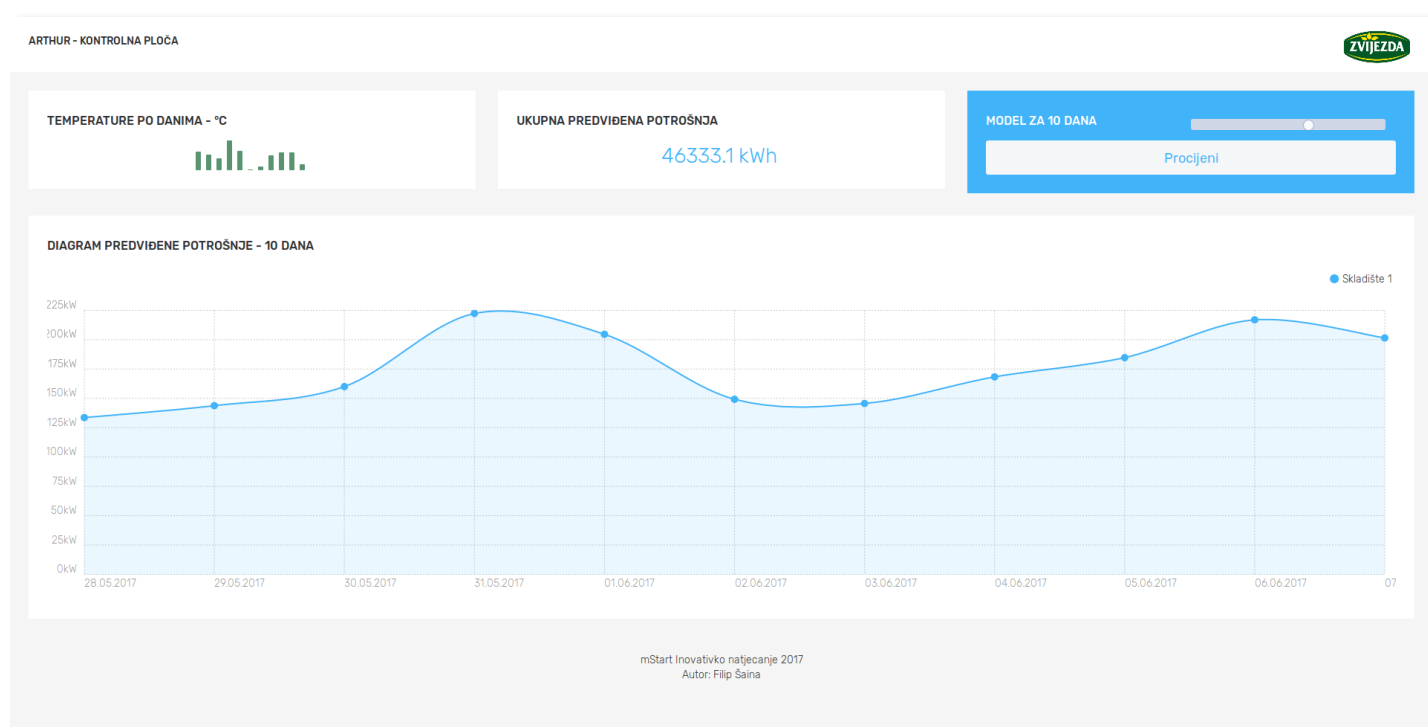
Slika 6. Vizualizacija predviđenih i stvarnih podataka za period od 38 dana

## 2.4. Web aplikacija

Zbog lakše interakcije sa sustavom te vizualizacija podataka napravljena je web aplikacija. Za razvoj je korišten popularni Python *framework* Django<sup>12</sup> sa GraphJS, Bootstrap, JQuery dodatcima. Krajnji rezultat je estetski ugodna aplikacija koja je informativna i jednostavna za korištenje, Slika 7.

Aplikacija se koristi tako da se postavi željeni broj dana za predikciju preko HTML klizača iznad “Procijeni” gumba, zatim pritiskom na gumb “Procijeni” kroz par trenutaka dobivamo vizulizaciju predikcije sustava.

Kroz razgovor sa stručnjacima iz DHMZ, generalni je zaključak da vremenske prognoze preko 10 data nisu mjerodavne te je vrlo moguće da se pokažu krivima. Iz tog razloga web aplikacija je predviđena za rad u intervalu predviđanja od 1 do 14 dana, sa uobičajnom vrijednošću od 10 dana.



Slika 7. Finalni izgled web aplikacije

<sup>12</sup> <https://www.djangoproject.com/>

Zbog velikog broja korištenih *frameworka*, cijeli sustav je zapakiran kao Docker projekt. Dockerizacijom projekta je omogućeno iznimno jednostavno pokretanje cijelog sustava na bilo kojem računalu ali i jednostavnu skalabilnost sustava u slučaju da to bude potrebno u budućnosti. Za pokretanje sustava potrebno je samo preko terminala preuzeti javno dostupnu Docker sliku Arthur predikcijskog sustava sa:

```
docker pull fsaina/arthur
```

Zatim pokrenuti instancu te slike sa:

```
docker run -p 8000:8000 fsaina/arthur
```

Ovime se pokreće Django server sa predikcijskim sustavom koji je pokrenut u virtualnom okruženju, unutar instance slike.

te u lokalnom Internet pregledniku otvoriti sljedeći URL:

```
localhost:8000
```

Za gašenje sustava dovoljno je samo ugasiti terminal kojim se pokrenuo server.

### 2.3.2. Korištene tehnologije

Tokom razvoja programskog rješenja neke od korištenih tehnologija su:



### 3. Industrijski benefiti sustava

Implementirani sustav uspješno predviđa trendove potrošnje koje mogu nastati prilikom različitih vremenskih i okolišnih uvijeta oko skladišta za čak do dva tjedna u budućnost<sup>13</sup> — pritom kvaliteta predikcije ovisi isključivo o kvaliteti podataka dobivenih iz sustava vremenske prognoze.

Trenutna implementacija, koja se pokazala potpuno spremnom za uporabu, donosi sljedeće benefite:

- Trenutačne novčane uštede kroz konzistentno korištenje sustava
- Logistički i organizacijski alat za bolje planiranje budućih događaja poput opasnosti od kvarenja i preopterećivanja sustava sa svrhom zaštite proizvoda koji su trenutno u skladištu
- Manji ekološki utisak u vidu iskorištene energije

Pritom je rukovodeća misao tokom izrade svih aspekata *Arthur* sustava bila ispravnost predikcije, jednostavnost uporabe i kvaliteta/ekstenzivnost programskog koda<sup>14</sup>.

Jedan od konkretnih primjera uporabe *Arthur* alata u industriji za ostvarivanje svih navedenih benefita je sljedeći — jedna od popularnih metoda ostvarivanja značajnih ušteda u velikim sustavima hlađenja poput skladišta je metoda stvaranja temperaturne banake u kojoj je ideja “smrznuti” skladište po noći, dok je jeftinija tarifa, na niske temperature te po danu uopće ne rashlađivati nego iskoristiti prethodno osiguranu hladnoću. *Arthur* — predikcijski sustav, može predvijeti nadolazeće šiljke u potrošnji izazvane vremenskim uvjetima te dati doznajanja nadgledniku da je trenutak za primjenu navedene metode i kojoj mjeri.

Nadalje, minimalnom modifikacijom trenutnog rješenja moguće je modelirati sustav da vrši predikciju maksimalnih dnevnih vrijednosti prosječne snage, tj snage po kojoj HEP<sup>15</sup> trenutno vrši mjesečni obračun. Ovime bi se moglo ostvariti novčane uštede u vidu licitiranja snage koju postrojenje bi moglo iskoristiti za aktualni mjesec<sup>16</sup>.

---

<sup>13</sup> Moguće je naravno i više dana u budućnost ali ti rezultati bi se mogli smatrati nepreciznima zbog nepredvidivih vremenskih uvijeta za više od 14 dana — DHMZ

<sup>14</sup> Cjelokupni programski kod korišten u izradi ovog rješenja je javno dostupan na <https://github.com/fsaina/Arthur>

<sup>15</sup> <http://www.hep.hr/>

<sup>16</sup> Ovaj sustav nije implementiran zato jer nije u domeni zadataka koji je predviđen natjecanjem.

## 4. Sugestije za daljnje poboljšanje sustava

Iako je greška predikcije sustava relativno malena te sustav se pokazao funkcionalnim, bitno je napomenuti da trenutna implementacija:

- Ne uzima u obzir svojstva pristupnih točaka skladišta, tj. energije izgubljene konvekcijom, strujanjem zraka kroz otvore skladišta na ukrcajnim točkama kao i ostalim otvorima na samom skladištu
- Ne uzima u obzir promjene u opterećenju sustava skladišta, odnosno model ne dobiva informaciju količine artikala koje su trenutnu u skladištu niti informacije o proizvodnom procesu
- Ne uzima u obzir potrošnju električnih i mehaničkih uređaja unutar samog skladišta koji svojim radom mogu zagrijavati okolni prostor

Dodavanjem navedenih podataka vjerojatno bismo dobili bolji sustav predikcije.

Za budući rad na ovom sustavu, neke od mogućnosti su:

- dodati prethodno navedene podatke i evaluirati rezultate u prethodno definiranoj arhitekturi<sup>17</sup> uz testiranja sustava sa podacima dobivenim od strane DHMZ<sup>18</sup>.
- akumulirati značajniji vremenski prozor bilježenja mjerenja snaga sustava, trenutni podatkovni skup se bilježi samo za prethodne dvije godine
- implementacija genetskih algoritama za optimizacija hiperparametara koja bi mogla doprinjeti poboljšanom modelu

---

<sup>17</sup> Pretpostavka je da uzimanje u obzir samo okolišnih čimbenika nisu dovoljni za potpuno modeliranje budućeg i trenutnog ponašanja parametara poput potrošnje električne energije kompleksnog sustava kao što je skladište.

<sup>18</sup> Testiranje sustava nad tim podacima nije provedeno zbog nedostupnosti podatka, odnosno cijene pribavljanja istih.

## 5. Reference

1. Applying LSTM to Time Series Predictable through Time-Window Approaches — Felix A. Gers, Douglas Eck, Jürgen Schmidhuber
2. Learning to Forget: Continual Prediction with LSTM — Felix A. Gers, Jürgen Schmidhuber and Fred Cummins
3. A Dual-Stage Attention-Based Recurrent Neural Network for Time Series Prediction — Yao Qin, Dongjin Song, Haifeng Cheng, Wei Cheng, Guofei Jiang, Garrison Cottrell
4. Time series prediction using support vector machines: a survey — Nicholas I. Sapankevych, Ravi Sankar
5. LSTM-in-LSTM for generating long descriptions of images — Jun Song, Siliang Tang, Jun Xiao, Fei Wu, and Zhongfei (Mark) Zhang